

BÁO CÁO ĐỒ ÁN: Phân loại khối u não trên ảnh MRI sử dụng Deep Learning

Giáo viên hướng dẫn: Cáp Phạm Đình Thăng

Nhóm BenuNet

Trường Đại học Công nghệ Thông tin - Đại học Quốc gia Thành phố Hồ Chí Minh

Ngày 6 tháng 1 năm 2026



UIT
TRƯỜNG ĐẠI HỌC
CÔNG NGHỆ THÔNG TIN

Nội dung báo cáo

- 1 Giới thiệu bài toán
- 2 Bộ dữ liệu
- 3 Các tiêu chí đánh giá
- 4 Phương pháp đề xuất
 - Chiến lược huấn luyện: Tinh chỉnh lũy tiến (Progressive Fine-tuning)
 - Chiến lược kết hợp mô hình (Ensemble Learning)
 - Chiến lược Test-Time Augmentation (TTA)
- 5 Explainable AI (XAI)
- 6 Kết luận

Tiến độ báo cáo

① Giới thiệu bài toán

② Bộ dữ liệu

③ Các tiêu chí đánh giá

④ Phương pháp đề xuất

Chiến lược huấn luyện: Tinh chỉnh lũy tiến (Progressive Fine-tuning)

Chiến lược kết hợp mô hình (Ensemble Learning)

Chiến lược Test-Time Augmentation (TTA)

⑤ Explainable AI (XAI)

⑥ Kết luận

Tổng quan đề tài

- **Bối cảnh y khoa (Context):**

U não là bệnh lý phức tạp với mức độ nguy hiểm cao. Việc phân loại chính xác các thể u trên ảnh cộng hưởng từ (MRI) là bước quan trọng nhất để bác sĩ đưa ra quyết định phẫu thuật hay xạ trị, ảnh hưởng trực tiếp đến tiên lượng sống của bệnh nhân.

- **Hạn chế của phương pháp truyền thống:**

Việc chẩn đoán thủ công đòi hỏi bác sĩ có trình độ chuyên môn cao và tốn nhiều thời gian. Hơn nữa, sự *biến thiên giữa các người quan sát* (*inter-observer variability*) và sự mệt mỏi có thể dẫn đến chẩn đoán sai hoặc bỏ sót các khối u nhỏ.

- **Mục tiêu và Giải pháp:**

Đề tài tập trung nghiên cứu và ứng dụng các kiến trúc mạng nơ-ron tích chập (Convolutional Neural Networks) tiên tiến nhằm xây dựng mô hình phân loại tự động. Mục tiêu là cung cấp một công cụ hỗ trợ chẩn đoán nhanh chóng, khách quan và đạt độ tin cậy cao cho đội ngũ y tế.

Tiến độ báo cáo

① Giới thiệu bài toán

② Bộ dữ liệu

③ Các tiêu chí đánh giá

④ Phương pháp đề xuất

Chiến lược huấn luyện: Tinh chỉnh lũy tiến (Progressive Fine-tuning)

Chiến lược kết hợp mô hình (Ensemble Learning)

Chiến lược Test-Time Augmentation (TTA)

⑤ Explainable AI (XAI)

⑥ Kết luận

Mô tả bộ dữ liệu (Dataset)

Nguồn dữ liệu

Nghiên cứu sử dụng bộ dữ liệu **Brain Tumor Dataset** được công bố trên **Figshare** (Jun Cheng.). Tập dữ liệu bao gồm **3.064** lát cắt MRI T1-weighted từ 233 bệnh nhân, được gán nhãn chi tiết bởi các chuyên gia. Bộ dữ liệu dùng cho kiểm định chéo 5 phần (5-fold cross-validation indices) cũng được cung cấp.

Phân bố nhãn (3 lớp)

- **Glioma Tumor:** U thần kinh đệm.(Gồm 1426 ảnh)
- **Meningioma Tumor:** U màng não.(Gồm 708 ảnh)
- **Pituitary Tumor:** U tuyến yên.(Gồm 930 ảnh)

Quy trình Tiền xử lý dữ liệu (Preprocessing)

Để đảm bảo tính ổn định và nâng cao khả năng tổng quát hóa của mô hình, quy trình tiền xử lý được thực hiện tuần tự qua các bước:

- **1. Trích xuất và Chuyển đổi định dạng:**

Dữ liệu gốc từ Figshare được lưu trữ dưới dạng tệp MATLAB (.mat). Bước đầu tiên thực hiện trích xuất dữ liệu và chuyển đổi sang định dạng ảnh .png để tương thích với các thư viện Deep Learning.

- **2. Tăng cường dữ liệu (Data Augmentation):**

Xây dựng pipeline tăng cường dữ liệu tự động sử dụng `tf.keras.Sequential` nhằm giảm thiểu Overfitting và tăng tính đa dạng cho tập Train:

- **Hình học:** Lật ngang (`RandomFlip 'horizontal'`), Xoay ngẫu nhiên (`RandomRotation 0.1`), Phóng to/thu nhỏ (`RandomZoom 0.1`).
- **Màu sắc:** Thay đổi độ tương phản (`RandomContrast 0.1`) và độ sáng (`RandomBrightness 0.1`).

Tiến độ báo cáo

① Giới thiệu bài toán

② Bộ dữ liệu

③ Các tiêu chí đánh giá

④ Phương pháp đề xuất

Chiến lược huấn luyện: Tinh chỉnh lũy tiến (Progressive Fine-tuning)

Chiến lược kết hợp mô hình (Ensemble Learning)

Chiến lược Test-Time Augmentation (TTA)

⑤ Explainable AI (XAI)

⑥ Kết luận

Các tiêu chí đánh giá

Các tiêu chí đánh giá hiệu suất của mô hình dựa trên Confusion Matrix:

- **Recall (Độ nhạy):** Tỷ lệ các trường hợp thực sự dương tính được mô hình dự đoán đúng.
$$Recall = \frac{TP}{TP+FN}$$

- **Specificity (Độ đặc hiệu):** Tỷ lệ các trường hợp thực sự âm tính được mô hình dự đoán đúng.
$$Specificity = \frac{TN}{TN+FP}$$

- **Precision (Độ chính xác tích cực):** Tỷ lệ dự đoán đúng trong tổng số các trường hợp được dự đoán là dương tính.
$$Precision = \frac{TP}{TP+FP}$$

- **F1-Score:** Giá trị trung bình điều hòa giữa Precision và Recall, giúp cân bằng khi dữ liệu bị mất cân bằng.
$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

- **Accuracy (Độ chính xác tổng thể):** Tỷ lệ số điểm dữ liệu được dự đoán đúng trên tổng số dữ liệu.
$$Accuracy = \frac{TP+TN}{TP+TN+FP+FN}$$

Tiến độ báo cáo

① Giới thiệu bài toán

② Bộ dữ liệu

③ Các tiêu chí đánh giá

④ Phương pháp đề xuất

Chiến lược huấn luyện: Tinh chỉnh lũy tiến (Progressive Fine-tuning)

Chiến lược kết hợp mô hình (Ensemble Learning)

Chiến lược Test-Time Augmentation (TTA)

⑤ Explainable AI (XAI)

⑥ Kết luận

Kiến trúc mô hình tổng quát

Mô hình được xây dựng dựa trên nguyên lý **Transfer Learning** với kiến trúc gồm 2 phần chính:

1. Trích xuất đặc trưng (Feature Extractor):

- Sử dụng mạng CNN nền tảng (Backbone) đã được huấn luyện trước trên tập dữ liệu lớn (ImageNet).
- Loại bỏ lớp phân loại gốc (Top layer), giữ lại các lớp tích chập để trích xuất đặc trưng (Feature maps).

2. Khối phân loại tùy chỉnh (Custom Head):

- **Global Average Pooling:** Giảm chiều dữ liệu không gian, tổng hợp đặc trưng.
- **Dropout:** Áp dụng tỷ lệ 0.3 để ngăn chặn Overfitting.
- **Output Layer:** Lớp Dense với hàm kích hoạt **Softmax** để đưa ra xác suất cho các lớp bệnh lý.

Hàm mất mát (Loss Function)

Áp dụng **Sparse Categorical Focal Loss** ($\gamma = 2.0$) thay vì Cross-Entropy tiêu chuẩn. Phương pháp này giúp mô hình tập trung học các mẫu khó (hard examples) và giảm thiểu tác động của mất cân bằng dữ liệu.

Chiến lược huấn luyện: Tinh chỉnh lũy tiến (Progressive Fine-tuning)

Thay vì tinh chỉnh toàn bộ mạng ngay lập tức, ta áp dụng chiến lược **Blockwise finetuning** kết hợp **5-Fold Cross-Validation**:

① Giai đoạn Warm-up:

Đóng băng toàn bộ Backbone, chỉ huấn luyện khối phân loại (Head) để trọng số hội tụ về miền giá trị phù hợp.

② Giai đoạn Tinh chỉnh sâu (Progressive Unfreezing):

Thực hiện unfreeze lần lượt từng khối (Block) của Backbone theo hướng từ lớp sâu đến lớp nông.

→ Giúp mô hình thích nghi dần với đặc trưng của ảnh MRI mà không phá vỡ các đặc trưng cấp thấp đã học từ ImageNet.

Cơ chế tối ưu hóa

Sử dụng bộ ba Callbacks: `ModelCheckpoint` (Lưu trọng số tốt nhất), `EarlyStopping` (Chống lãng phí tài nguyên) và `ReduceLROnPlateau` (Điều chỉnh Learning Rate linh hoạt).

Mô hình: DenseNet121

Cấu hình Fine-tuning	Recall (%)	Specificity (%)	Precision (%)	F1-Score (%)	Accuracy (%)
FT: B ₁ -B ₆	90.97	96.05	91.34	90.85	92.02
FT: B₂-B₆	91.25	96.13	91.26	90.98	92.17
FT: B ₃ -B ₆	90.07	95.65	90.58	89.97	91.30
FT: B ₄ -B ₆	89.68	95.53	90.25	89.65	91.15
FT: B ₅ -B ₆	87.76	94.55	87.83	87.56	89.19
FT: B ₆	85.16	93.15	84.47	84.44	86.34

Bảng: So sánh hiệu năng qua các giai đoạn unfreeze DenseNet121

Mô hình: Xception

Cấu hình Fine-tuning	Recall (%)	Specificity (%)	Precision (%)	F1-Score (%)	Accuracy (%)
FT: B ₁ -B ₅	89.56	95.30	90.16	89.58	90.88
FT: B₂-B₅	90.12	95.68	90.89	90.27	91.61
FT: B ₃ -B ₅	88.87	95.04	89.78	89.04	90.50
FT: B ₄ -B ₅	87.59	94.50	88.51	87.64	89.29
FT: B ₅	83.17	92.47	84.48	83.41	85.78

Bảng: So sánh hiệu năng qua các giai đoạn unfreeze Xception

Mô hình: MobileNet

Cấu hình Fine-tuning	Recall (%)	Specificity (%)	Precision (%)	F1-Score (%)	Accuracy (%)
FT: B₁-B₅	90.08	95.50	89.70	89.84	90.98
FT: B ₂ -B ₅	88.99	95.23	89.70	89.10	90.66
FT: B ₃ -B ₅	88.64	95.12	89.19	88.55	90.28
FT: B ₄ -B ₅	87.25	94.44	87.31	87.00	88.81
FT: B ₅	85.12	93.60	86.02	84.89	87.33

Bảng: So sánh hiệu năng qua các giai đoạn unfreeze MobileNet

Mô hình: MobileNetV2

Cấu hình Fine-tuning	Recall (%)	Specificity (%)	Precision (%)	F1-Score (%)	Accuracy (%)
FT: B ₁ -B ₅	88.92	94.71	87.16	87.63	88.70
FT: B₂-B₅	88.92	94.86	87.89	88.20	89.44
FT: B ₃ -B ₅	87.60	94.25	87.04	87.12	88.32
FT: B ₄ -B ₅	85.92	93.70	86.26	85.84	87.68
FT: B ₅	85.95	93.43	84.68	85.06	86.47

Bảng: So sánh hiệu năng qua các giai đoạn unfreeze MobileNetV2

Kết quả thực nghiệm

Mô hình: ResNet50

Cấu hình Fine-tuning	Recall (%)	Specificity (%)	Precision (%)	F1-Score (%)	Accuracy (%)
FT: B₁-B₆	90.17	95.79	91.73	90.62	91.99
FT: B ₂ -B ₆	90.06	95.77	91.73	90.35	91.90
FT: B ₃ -B ₆	88.45	94.89	91.19	89.38	90.84
FT: B ₄ -B ₆	89.45	95.36	91.17	89.99	91.39
FT: B ₅ -B ₆	87.69	94.51	88.62	87.86	89.53
FT: B ₆	85.61	93.41	85.65	85.35	87.16

Bảng: So sánh hiệu năng qua các giai đoạn unfreeze ResNet50

Mô hình: ResNet50V2

Cấu hình Fine-tuning	Recall (%)	Specificity (%)	Precision (%)	F1-Score (%)	Accuracy (%)
FT: B₁-B₆	90.19	95.62	91.55	90.71	91.89
FT: B ₂ -B ₆	89.84	95.61	90.40	89.88	91.37
FT: B ₃ -B ₆	89.98	95.74	90.63	90.03	91.56
FT: B ₄ -B ₆	88.41	95.06	89.29	88.50	90.27
FT: B ₅ -B ₆	88.72	95.06	89.07	88.74	90.29
FT: B ₆	85.25	93.44	85.88	85.38	87.27

Bảng: So sánh hiệu năng qua các giai đoạn unfreeze ResNet50V2

Kết quả thực nghiệm

Mô hình: VGG16


Cấu hình Fine-tuning	Recall (%)	Specificity (%)	Precision (%)	F1-Score (%)	Accuracy (%)
FT: B ₁ -B ₆	92.41	96.72	92.91	92.49	93.50
FT: B₂-B₆	92.82	96.90	93.18	92.85	93.85
FT: B ₃ -B ₆	91.77	96.38	91.95	91.70	92.75
FT: B ₄ -B ₆	91.05	96.02	90.60	90.65	91.82
FT: B ₅ -B ₆	88.58	94.79	88.13	88.21	89.57
FT: B ₆	84.44	92.86	83.95	83.86	85.75

Bảng: So sánh hiệu năng qua các giai đoạn unfreeze VGG16

Mô hình: VGG19

Cấu hình Fine-tuning	Recall (%)	Specificity (%)	Precision (%)	F1-Score (%)	Accuracy (%)
FT: B₁-B₆	93.17	96.97	93.54	93.22	94.01
FT: B ₂ -B ₆	91.26	96.26	92.05	91.32	92.60
FT: B ₃ -B ₆	90.64	95.98	91.05	90.63	91.92
FT: B ₄ -B ₆	90.72	95.94	91.15	90.72	91.96
FT: B ₅ -B ₆	88.37	94.82	87.86	87.90	89.47
FT: B ₆	82.13	91.98	81.55	81.50	83.86

Bảng: So sánh hiệu năng qua các giai đoạn unfreeze VGG19



Hình: Comparison of Accuracy between best Blockwise finetuning models

Chiến lược kết hợp mô hình (Ensemble Learning)

Tại sao lựa chọn phương pháp Ensemble?

- **Tận dụng sự đa dạng kiến trúc (Diversity):**

Mỗi kiến trúc mạng CNN (về độ sâu, độ rộng, hay cơ chế kết nối) sẽ có cách trích xuất đặc trưng khác nhau. Việc kết hợp giúp hệ thống có được “góc nhìn” đa chiều về dữ liệu hình ảnh.

- **Cải thiện độ ổn định (Variance Reduction):**

Hệ thống kết hợp thường ít nhạy cảm với nhiễu (noise) hơn so với một mô hình đơn lẻ, giúp giảm thiểu hiện tượng Overfitting và tăng khả năng tổng quát hóa (Generalization) trên tập dữ liệu kiểm thử.

Công thức tổng quát

Nhấn dự đoán cuối cùng $\hat{y}$ được xác định bằng cách lấy trung bình xác suất tin cậy của N mô hình thành viên:

$$\hat{y} = \arg \max_c \left(\frac{1}{N} \sum_{i=1}^N P_i(c) \right)$$

Mô hình: ensemble 5 model

	Recall	Specificity	Precision	F1-Score	Accuracy
VGG19+ResNet50 +DenseNet121 +Xception+MobileNet	92.95	96.94	93.36	93.01	93.94

Bảng: Metrics mô hình ensemble 5 model

Kết quả thực nghiệm

Mô hình ensemble 4 model

	Recall	Specificity	Precision	F1-Score	Accuracy
VGG19+ResNet50 +Xception+MobileNet	93.13	97.03	93.50	93.22	94.11
VGG19+DenseNet121 +Xception+MobileNet	93.02	96.92	93.00	92.88	93.78
DenseNet121+ResNet50 +VGG19+MobileNet	93.08	96.98	93.37	93.09	93.98
DenseNet121+ResNet50 +VGG19+Xception	92.76	96.87	93.22	92.82	93.78
DenseNet121+ResNet50 +Xception+MobileNet	92.14	96.60	92.78	92.29	93.35

Bảng: Metrics mô hình ensemble 4 model

Mô hình ensemble 3 model

	Recall	Specificity	Precision	F1-Score	Accuracy
VGG19+Xception +MobileNet	93.15	96.98	93.29	93.14	93.96
VGG19+ResNet50 +MobileNet	92.85	96.92	93.32	92.98	93.90
VGG19+ResNet50 +Xception	92.84	96.91	93.35	92.95	93.90
VGG19+DenseNet121 +ResNet50	92.77	96.90	93.35	92.90	93.86
VGG19+DenseNet121 +MobileNet	93.13	96.98	93.09	92.99	93.85

Bảng: Metrics mô hình ensemble 3 model

Kết quả thực nghiệm

Mô hình ensemble 3 model

	Recall	Specificity	Precision	F1-Score	Accuracy
VGG19+DenseNet121 +Xception	92.86	96.90	92.98	92.78	93.74
DenseNet121+MobileNet +ResNet50	92.02	96.53	92.62	92.16	93.21
DenseNet121+ResNet50 +Xception	91.56	96.36	92.36	91.74	92.89
DenseNet121+Xception +MobileNet	91.91	96.45	91.77	91.66	92.77
ResNet50+Xception +MobileNet	91.79	96.48	92.53	92.00	93.14

Bảng: Metrics mô hình ensemble 3 model

Mô hình ensemble 2 model

	Recall	Specificity	Precision	F1-Score	Accuracy
VGG19+MobileNet	93.73	97.22	93.74	93.65	94.38
VGG19+Xception	92.93	96.94	93.29	92.98	93.88
VGG19+DenseNet121	93.11	96.94	93.07	92.96	93.79
VGG19+ResNet50	92.48	96.81	93.34	92.74	93.77
Xception+MobileNet	91.66	96.29	91.42	91.47	92.51


Bảng: Metrics mô hình ensemble 2 model

Mô hình ensemble 2 model

	Recall	Specificity	Precision	F1-Score	Accuracy
DenseNet121+Xception	91.59	96.32	91.74	91.44	92.60
DenseNet121+MobileNet	91.85	96.37	91.46	91.52	92.58
DenseNet121+ResNet	91.02	96.16	92.05	91.24	92.54
ResNet50+MobileNet	91.67	96.39	92.35	91.88	92.97
ResNet50+Xception	90.59	95.99	91.83	90.93	92.29

Bảng: Metrics mô hình ensemble 2 model

Comparison of Accuracy



Hình: Comparison of Accuracy between best Ensemble models across different group sizes (2 to 5 base models)

Kỹ thuật nâng cao: Test-Time Augmentation (TTA)

- **Cơ chế hoạt động:** Không chỉ dự đoán trên ảnh gốc, hệ thống tự động sinh ra các *biến thể* (lật ngang, thay đổi độ sáng ± 0.1 , độ tương phản ± 0.1) ngay tại thời điểm kiểm thử (Test phase).
- **Kết hợp Ensemble:** Mỗi biến thể được đưa qua tất cả các mô hình trong tổ hợp Ensemble. Kết quả cuối cùng được tổng hợp dựa trên **Soft Voting** (trung bình cộng xác suất).
- **Công thức tổng quát:**

$$P_{final} = \frac{1}{K \times N} \sum_{k=1}^K \sum_{n=1}^N M_k(T_n(x))$$

Trong đó: K là số mô hình, N là số biến thể TTA, T_n là phép biến đổi ảnh.

Kết quả thực nghiệm

Mô hình: tta-ensemble 5 model

	Recall	Specificity	Precision	F1-Score	Accuracy
VGG19+ResNet50 +DenseNet121 +Xception+MobileNet	93.10	97.00	93.42	93.14	94.03

Bảng: Metrics mô hình tta-ensemble 5 model

Mô hình: tta-ensemble 4 model

	Recall	Specificity	Precision	F1-Score	Accuracy
VGG19+ResNet50 +Xception+MobileNet	93.11	97.03	93.55	93.23	94.12
DenseNet121+ResNet50 +Xception+MobileNet	92.40	96.70	92.92	92.50	93.52

Bảng: Metrics mô hình tta-ensemble 4 model

Kết quả thực nghiệm

Mô hình: tta-ensemble 3 model

	Recall	Specificity	Precision	F1-Score	Accuracy
VGG19+Xception +MobileNet	93.54	97.16	93.60	93.49	94.26
DenseNet121+ResNet50 +MobileNet	92.27	96.66	92.87	92.42	93.44
ResNet50+Xception +MobileNet	91.98	96.56	92.75	92.22	93.32


Bảng: Metrics mô hình tta-ensemble 3 model

Mô hình: tta-ensemble 2 model

	Recall	Specificity	Precision	F1-Score	Accuracy
VGG19+MobileNet	93.83	97.27	93.80	93.73	94.47
ResNet50+MobileNet	91.78	96.47	92.66	92.08	93.17
Xception+MobileNet	91.94	96.44	91.87	91.83	92.86
DenseNet121+Xception	91.60	96.28	91.68	91.43	92.53

Bảng: Metrics mô hình tta-ensemble 2 model

Comparison of Accuracy



Hình: Comparison of Accuracy between best TTA-Ensemble models across different group sizes (2 to 5 base models)

Tiến độ báo cáo

① Giới thiệu bài toán

② Bộ dữ liệu

③ Các tiêu chí đánh giá

④ Phương pháp đề xuất

Chiến lược huấn luyện: Tinh chỉnh lũy tiến (Progressive Fine-tuning)

Chiến lược kết hợp mô hình (Ensemble Learning)


Chiến lược Test-Time Augmentation (TTA)

⑤ Explainable AI (XAI)

⑥ Kết luận

Trực quan hóa kết quả (Grad-CAM)

Để tăng tính minh bạch của mô hình (Explainable AI), sử dụng kỹ thuật **Grad-CAM** để hiển thị vùng đặc trưng mà mô hình tập trung vào.



Vùng màu đỏ thể hiện khu vực mô hình “nhìn vào” để đưa ra dự đoán khối u.

Tiến độ báo cáo

① Giới thiệu bài toán

② Bộ dữ liệu

③ Các tiêu chí đánh giá

④ Phương pháp đề xuất

Chiến lược huấn luyện: Tinh chỉnh lũy tiến (Progressive Fine-tuning)

Chiến lược kết hợp mô hình (Ensemble Learning)

Chiến lược Test-Time Augmentation (TTA)

⑤ Explainable AI (XAI)

⑥ Kết luận

Kết luận và Hướng phát triển

Kết luận

- Xây dựng thành công quy trình xử lý và phân loại u não tự động với độ chính xác trên 94 phần trăm.
- Ứng dụng kỹ thuật Transfer Learning giúp mô hình hội tụ nhanh và hiệu quả trên tập dữ liệu nhỏ.
- Hỗ trợ trực quan hóa vùng bệnh lý thông qua Heatmap.

Hướng phát triển trong tương lai

- Cải thiện độ chính xác.
- Mở rộng tập dữ liệu với các ca bệnh hiếm.
- Tích hợp bài toán **Segmentation** (Phân vùng) để đo kích thước khối u.
- Triển khai hệ thống lên máy tính bệnh viện để hỗ trợ bác sĩ.

- [1] Z. N. K. Swati *et al.*, "Brain tumor classification for MR images using transfer learning and fine-tuning," *Computerized Medical Imaging and Graphics*, vol. 75, pp. 34–46, Jul. 2019.
<https://doi.org/10.1016/j.compmedimag.2019.05.001>
- [2] S. Deepak and P. M. Ameer, "Brain tumor categorization from imbalanced MRI dataset using weighted loss and deep feature fusion," *Neurocomputing*, vol. 520, pp. 94–102, Feb. 2023.
<https://doi.org/10.1016/j.neucom.2022.11.039>
- [3] G. Wang, W. Li, M. Aertsen, J. Deprest, S. Ourselin, and T. Vercauteren, "Aleatoric uncertainty estimation with test-time augmentation for medical image segmentation with convolutional neural networks," *Neurocomputing*, vol. 338, pp. 34–45, Apr. 2019.
<https://doi.org/10.1016/j.neucom.2019.01.103>